

CEMP

Centro Europeo de Másteres y Posgrados

Máster en Bioinformática y Bioestadística

TRABAJO FINAL DE MÁSTER

Desarrollo y evaluación de modelos de machine learning supervisado para la clasificación de estadios de enfermedad hepática asociada a hepatitis C a partir de parámetros clínicos y bioquímicos

Alumna: Ana Paula Adobato

Directora: Sara Lopez

Curso académico: año 2025 - 2026

Barcelona, abril 2026

1. ÍNDICE

1. Índice	1
2. Lista de tablas y figuras	2
3. Abreviaturas	3
4. Resumen	4
5. Introducción	5
6. Objetivos	10
7. Metodología	11
7.1 Fuente de datos	11
7.2 Variables incluidas en el análisis	12
7.3 Preprocesamiento de datos	13
7.4 Análisis exploratorio de datos	14
7.5 Desarrollo de modelos predictivos	14
7.6 Modelos evaluados	15
7.7 Métricas de evaluación	16
7.8 Análisis de variables relevante y contrastes de hipótesis ...	16
8. Resultados.....	16
8.1 Descripción del dataset	16
8.2 Análisis exploratorio de los datos	18
8.3 Modelos de machine learning	23
8.4 Variables relevantes.....	26
8.5 Contrastes de hipótesis.....	27
8.6 Estadísticas descriptivas por categoría diagnostica.....	28
9. Discusión	29
10. Conclusión	38
11. Bibliografía	39
12. Anexo: Código utilizado	42

2. LISTA DE TABLAS Y FIGURAS

Figuras

1. **Figura 1.** Distribución de las categorías diagnósticas en el dataset tras la exclusión de casos "suspect blood donor" (n=608) Pag.
2. **Figura 2.** Mapa de calor de correlaciones entre las variables clínicas y bioquímicas incluidas en el análisis Pag.
3. **Figura 3.** Distribución de ALT según categoría diagnóstica (0=sano, 1=hepatitis, 2=fibrosis, 3=cirrosis). Pag.
4. **Figura 4.** Distribución de AST según categoría diagnóstica. Pag.
5. **Figura 5.** Distribución de ALB según categoría diagnóstica. Pag.
6. **Figura 6.** Distribución de GGT según categoría diagnóstica. Pag.
7. **Figura 7.** Distribución de BIL según categoría diagnóstica. Pag.
8. **Figura 8.** Matriz de confusión del modelo de regresión logística estándar.. Pag.
9. **Figura 9.** Matriz de confusión del modelo Random Forest. Pag.
10. **Figura 10.** Matriz de confusión del modelo de regresión logística ponderada (class_weight='balanced'). Pag.

Tablas

1. **Tabla 1.** Características demográficas y distribución diagnóstica de la muestra tras el preprocesamiento del dataset. Pag
2. **Tabla 2.** Descripción de las variables incluidas en el análisis: tipo, unidad y frecuencia de valores faltantes antes de la imputación. Pag.
3. **Tabla 3.** Resultados del modelo de regresión logística: precisión, sensibilidad, F1-score y soporte por clase. Pag
4. **Tabla 4.** Resultados del modelo Random Forest: precisión, sensibilidad, F1-score y soporte por clase. Pag
5. **Tabla 5.** Resultados del modelo de regresión logística ponderada (class_weight='balanced'): precisión, sensibilidad, F1-score y soporte por clase. Pag
6. **Tabla 6.** Comparación del rendimiento global de los tres modelos evaluados. Pag

7. **Tabla 7.** Coeficientes del modelo de regresión logística ponderada para las variables con mayor contribución en la clasificación. Pag
8. **Tabla 8.** Resultados del test de Kruskal-Wallis para las variables con diferencias estadísticamente significativas entre grupos diagnósticos. Pag
9. **Tabla 9.** Estadísticas descriptivas de los biomarcadores por categoría diagnóstica. Pag

3. ABREVIATURAS EMPLEADAS

Abreviatura	Significado
ALB	Albúmina
ALP	Fosfatasa alcalina (Alkaline Phosphatase)
ALT	Alanina aminotransferasa
AST	Aspartato aminotransferasa
BIL	Bilirrubina
CHE	Colinesterasa
CHOL	Colesterol
CREA	Creatinina
EDA	Análisis Exploratorio de Datos (Exploratory Data Analysis)
EASL	Asociación Europea para el Estudio del Hígado (European Association for the Study of the Liver)
ESPEN	Sociedad Europea de Nutrición Clínica y Metabolismo (European Society for Clinical Nutrition and Metabolism)
F1	Valor F1 (media armónica entre precisión y sensibilidad)
GGT	Gamma-glutamyl transferasa
HCV	Virus de la Hepatitis C (Hepatitis C Virus)
ML	Machine Learning (Aprendizaje Automático)
OMS	Organización Mundial de la Salud
WHO	Organización Mundial de la Salud (World Health Organization)
PROT	Proteínas totales
CSV	Archivo de valores separados por comas (Comma Separated Values)

4. RESUMEN

La enfermedad hepática constituye un problema relevante en la salud pública a nivel mundial. El hígado es un órgano clave en múltiples procesos metabólicos y su detección temprana es fundamental para evitar progresiones hacia estadios mas avanzados como la fibrosis, cirrosis o el desarrollo de complicaciones sistémicas. En este contexto, el presente trabajo tuvo como objetivo clasificar los distintos estadios de la enfermedad hepática asociados a hepatitis C a partir de parámetros clínicos y bioquímicos, mediante el desarrollo y comparación de modelos de machine learning supervisado.

Se analizaron datos clínicos proporcionados por el Máster, que incluyen variables demográficas y biomarcadores de uso habitual en la práctica clínica rutinaria. Tras el procesamiento y limpieza de los datos, se llevó a cabo un análisis exploratorio que permitió identificar, entre otras cosas, un marcado desbalance entre las categorías diagnósticas con predominio claro de individuos sanos frente a los grupos patológicos. A partir de ahí se desarrollaron tres modelos predictivos, entre ellos regresión logística, Random Forest y regresión logística ponderada, esta última incorporada para abordar dicho desbalance.

Los resultados mostraron un rendimiento global favorable en los tres modelos. Sin embargo, la regresión logística balanceada se destacó por ofrecer un equilibrio real entre precisión global y capacidad de detección de los estadios patológicos, con una sensibilidad del 80% para hepatitis, 75% para fibrosis y 83% para cirrosis. Las variables que mayor peso presentaron fueron las que corresponden principalmente a los parámetros clásicos de la función hepática (ALP, albumina, ALT, GGT, bilirrubina y AST), lo que, desde mi punto de vista, refuerza la coherencia biológica y clínica de los resultados obtenidos.

Estos hallazgos sugieren que el uso de modelos de machine learning basados en analíticas clínicas estándar podría representar una herramienta complementaria util en los diagnósticos clínicos y prevención. A su vez, la incorporación futura de variables nutricionales y metabólicas podría optimizar la capacidad predictiva de estos modelos y así permitir una evaluación más integral del paciente con enfermedad hepática.

5. INTRODUCCIÓN

La enfermedad hepática presenta una elevada prevalencia y puede generar importantes consecuencias clínicas cuando no se detecta de forma temprana y es por ello que constituye un problema relevante en salud pública a nivel mundial. Entre sus principales causas más importantes se encuentra la infección por el virus de la hepatitis C (HCV), que afecta a millones de personas en todo el mundo y representa una de las principales causas de enfermedad hepática crónica (World Health Organization, 2017). La progresión de esta infección puede aumentar hasta convertirse en fibrosis, cirrosis o incluso en carcinoma hepatocelular si no se detecta de manera precoz. En muchos casos, la enfermedad puede ser asintomática durante mucho tiempo, lo que genera un diagnóstico más tardío y favorece la progresión hacia estadios más avanzados de daño hepático (Safdari et al., 2022; EASL, 2018).

En el contexto europeo y español, la infección por HCV presenta una epidemiología relevante aunque con tendencia decreciente gracias a las intervenciones terapéuticas de los últimos años. Según datos de seguimiento del Plan Estratégico para el Abordaje de la Hepatitis C en España, desde 2015 hasta mediados de 2023 se han tratado más de 164.000 personas con antivirales de acción directa, alcanzando tasas de curación del 95%. Paralelamente, el porcentaje de pacientes que inicia tratamiento en fase avanzada de la enfermedad ha descendido del 62% en 2016 al 29% en 2022 (Coalition for Global Hepatitis Elimination, 2024; Ministerio de Sanidad, 2023), lo que refleja los avances en el diagnóstico precoz. Sin embargo, la existencia de casos no diagnosticados sigue siendo un desafío clínico relevante, especialmente en poblaciones vulnerables. En España, según el estudio de seroprevalencia publicado en 2020, la prevalencia de infección activa por VHC en población de 20 a 80 años fue de 0,22%, y entre el 55% y el 85% de los infectados desarrollarán infección crónica, de los cuales entre el 15% y el 30% evolucionarán a cirrosis hepática en un plazo de 20 años (Hernando et al., 2024). Estos datos ponen de manifiesto la importancia de disponer de herramientas de clasificación y estratificación tempranas que permitan identificar a los pacientes en riesgo de progresión antes de que alcancen estadios avanzados de daño hepático.

A nivel europeo, la situación tampoco es menor. Según los datos del Centro Europeo para la Prevención y el Control de Enfermedades, se estima que aproximadamente 1,8 millones de personas viven con infección activa por HCV en la Unión Europea y el Espacio Económico Europeo, lo que representa alrededor del 0,5% de la población, con unas

64.000 muertes atribuibles a la enfermedad cada año (ECDC, 2024). En 2023 se notificaron 28.622 casos nuevos en 29 países de la Unión Europea, correspondientes a una tasa bruta de 7,4 casos por 100.000 habitantes, de los cuales el 34,1% fueron clasificados como casos crónicos (ECDC, 2025). La vía de transmisión más frecuente en Europa sigue siendo el uso de drogas por vía parenteral, lo que hace que las estrategias de reducción de daño sean especialmente relevantes en este contexto (y también que muchos casos permanezcan sin diagnosticar durante años por la dificultad de acceso de estas poblaciones al sistema sanitario).

La Organización Mundial de la Salud fijó como objetivo global la eliminación de la hepatitis C como problema de salud pública para el año 2030. Sin embargo, el progreso hacia ese objetivo en Europa sigue siendo insuficiente, en parte por el impacto de la pandemia de COVID-19 en los sistemas de vigilancia y tratamiento, que interrumpió o retrasó muchos programas de cribado y seguimiento (Maticic et al., 2024). Esta realidad pone de manifiesto, una vez más, la importancia de desarrollar herramientas diagnósticas y de estratificación accesibles que puedan contribuir a identificar casos no diagnosticados y a mejorar el seguimiento de los pacientes en distintos contextos sanitarios (que es precisamente lo que este trabajo intenta explorar, aunque a pequeña escala).

En este contexto, los biomarcadores utilizados en este trabajo representan parámetros de uso rutinario en la práctica clínica con valor diagnóstico y pronóstico reconocido en la enfermedad hepática. Las pruebas de función hepática incluyen habitualmente ALT, AST, ALP, GGT, bilirrubina, proteínas totales y albúmina, y permiten determinar el área de daño hepático según el patrón de elevación observado (Thapa & Walia, 2007). Entre ellos, ALT y AST son los marcadores de daño hepatocelular más utilizados en la práctica clínica. ALT es considerada un mejor indicador de daño hepático que AST porque su actividad es significativamente mayor en el hígado que en el músculo, lo que le confiere mayor especificidad hepática. Sin embargo, en la hepatitis C crónica ambas enzimas tienen valor complementario: el cociente AST/ALT aumenta con la progresión histológica de la fibrosis, y un valor igual o superior a 1 es altamente sugestivo de cirrosis en pacientes con infección crónica por VHC (Ozer et al., 2008).

La GGT es una enzima que puede elevarse tanto en condiciones de daño hepatocelular como de colestasis, y su medición resulta especialmente útil para confirmar el origen hepático de una elevación de ALP (Kwo et al., 2017). En el contexto de la hepatitis C crónica, los niveles de GGT aumentan con la progresión de la enfermedad y han sido

estudiados como predictores de respuesta al tratamiento (Ermaya, 2023). La bilirrubina, producto final del catabolismo del grupo hemo, refleja la capacidad del hígado para conjuguar y excretar pigmentos biliares. Su elevación, especialmente de la fracción conjugada, indica deterioro de la función excretora hepática o colestasis (Kwo et al., 2017). La albúmina, por su parte, es la proteína plasmática más abundante sintetizada por el hígado, y su disminución es un indicador sensible del deterioro de la capacidad sintética hepática en estadios avanzados de la enfermedad. Los niveles de albúmina se correlacionan con el pronóstico en pacientes con cirrosis y se utilizan como componente de escalas de gravedad como Child-Pugh (Pratt & Kaplan, 2000). La inclusión de estos biomarcadores en el análisis responde a su disponibilidad universal en los estudios analíticos de rutina y a su reconocido valor clínico en la evaluación del daño hepático (Ali et al., 2023; EASL, 2018).

La fosfatasa alcalina (ALP) es un marcador principalmente asociado a colestasis y obstrucción biliar. Su elevación de origen hepático se confirma cuando se acompaña de un aumento concomitante de GGT (Kwo et al., 2017). La colinesterasa (CHE) es una enzima sintetizada casi exclusivamente en el hígado, por lo que sus niveles séricos reflejan directamente la capacidad sintética hepática. Se ha demostrado que los niveles de CHE disminuyen significativamente en pacientes con hepatitis crónica y cirrosis, lo que la convierte en un marcador útil para el diagnóstico y pronóstico del daño hepático (Mohammed et al., 2017). El colesterol, también sintetizado en el hígado, tiende a disminuir en estadios avanzados de la enfermedad hepática como reflejo del deterioro metabólico progresivo. Finalmente, la creatinina, aunque es principalmente un marcador de función renal, puede verse alterada en pacientes con cirrosis avanzada en el contexto del síndrome hepatorenal, lo que justifica su inclusión en el análisis (Kwo et al., 2017). La inclusión de todos estos biomarcadores en el análisis responde a su disponibilidad universal en los estudios analíticos de rutina y a su reconocido valor clínico en la evaluación del daño hepático (Ali et al., 2023; EASL, 2018).

El hígado es, en cierta forma, uno de los órganos más silenciosos y a la vez mas indispensables del organismo. Desarrolla un papel fundamental en numerosos procesos metabólicos, por ejemplo, en el metabolismo de proteínas y lípidos, en la detoxificación de sustancias y en la síntesis de diversas proteínas plasmáticas. Es por esto que las alteraciones en la función hepática generan cambios en diferentes biomarcadores clínicos, como en las transaminasas, la albúmina o la bilirrubina, entre otros. Estos parámetros

forman parte de pruebas de análisis clínicos de rutinas utilizados frecuentemente en la práctica clínica para evaluar el estado de la función del hígado y son útiles para detectar posibles alteraciones hepáticas (Ali et al., 2023). A esto se suma que, en pacientes con enfermedad hepática crónica es frecuente observar riesgo de malnutrición, lo que puede influir en la evolución clínica como en la interpretación de diferentes biomarcadores analíticos (Plauth et al., 2019). Es un aspecto que muchas veces queda en segundo plano pero que tiene implicaciones reales en el manejo del paciente.

En los últimos años, el aumento en la disponibilidad de los datos clínicos y el desarrollo de herramientas computacionales han impulsado el uso de técnicas de inteligencia artificial en el ámbito de la medicina y biología. Los métodos de machine learning demostraron ser útiles para analizar grandes volúmenes de datos y para desarrollar modelos predictivos que contribuyan a la prevención, diagnóstico y clasificación de enfermedades. En el campo específico de la hepatitis C, diversos estudios exploraron el uso de algoritmos de aprendizaje automático para identificar patrones en datos clínicos asociados con hepatitis C y otras enfermedades hepáticas, mostrando resultados prometedores en la predicción del diagnóstico (Majzoobi et al., 2022; Butt et al., 2021). Es un área que está creciendo rápido y que, desde mi punto de vista, tiene mucho potencial todavía sin explotar, especialmente en contextos clínicos de recursos limitados.

En los últimos años, el aumento en la disponibilidad de datos clínicos y el desarrollo de herramientas computacionales han impulsado fuertemente el uso de técnicas de inteligencia artificial en medicina. Los métodos de machine learning demostraron ser útiles para analizar grandes volúmenes de datos y construir modelos predictivos que contribuyan a la prevención, el diagnóstico y la clasificación de enfermedades. En el campo específico de la hepatitis C, varios estudios exploraron el uso de algoritmos de aprendizaje automático para identificar patrones en datos clínicos, con resultados prometedores (Majzoobi et al., 2022; Butt et al., 2021). Y aunque los avances son innegables, la realidad es que la mayoría de los modelos publicados se desarrollan sobre grandes bases de datos hospitalarias que poco tienen que ver con los recursos disponibles en un centro de atención primaria o en una consulta de hepatología de tamaño medio.

La aplicación de la inteligencia artificial en hepatología ha crecido de forma notable en los últimos años y es, sin duda, una de las áreas más interesantes de explorar. Durante las últimas dos décadas, la hepatología ha experimentado avances significativos en herramientas diagnósticas, modelos pronósticos y opciones de tratamiento,

convirtiéndose en una de las subespecialidades médicas más complejas. En este contexto, la inteligencia artificial está permitiendo que los ordenadores aprendan de conjuntos de datos clínicos complejos y diversos para resolver problemas médicos reales con un rendimiento que, en algunas áreas, supera al de los propios médicos (Tincopa & Loomba, 2023). Las aplicaciones van desde el análisis de imágenes hepáticas y la interpretación de histopatología hasta el desarrollo de modelos de predicción de riesgo y estratificación de pacientes. De hecho, en el Congreso de la EASL de 2024 celebrado en Milán, aproximadamente el 4% de los trabajos presentados utilizaron métodos de inteligencia artificial, con un predominio de los métodos de machine learning sobre datos tabulares clínicos (precisamente el tipo de datos utilizado en este trabajo) seguidos del aprendizaje profundo sobre datos de imagen (Hartl et al., 2024).

Sin embargo, y pese a estos avances, la implementación real de estos modelos en la práctica clínica sigue siendo limitada. La validación prospectiva rigurosa, las barreras regulatorias y los problemas de financiación son algunos de los principales obstáculos que frenan su adopción (Hartl et al., 2024). A esto se suma que muchos modelos desarrollados en entornos de investigación están basados en grandes bases de datos que no siempre son representativas de la población atendida en centros clínicos más pequeños. Esta brecha entre lo que se desarrolla en investigación y lo que puede aplicarse en la práctica cotidiana es, precisamente, la que este trabajo intenta abordar desde una escala más modesta pero más cercana a la realidad clínica habitual.

Entre los enfoques más utilizados se encuentran algoritmos de aprendizaje supervisados como la regresión logística, los árboles de decisión o Random Forest. Estos modelos permiten analizar simultáneamente múltiples variables clínicas y bioquímicas con el objetivo de identificar combinaciones de factores que puedan ayudar a clasificar a los pacientes según su estado de salud o estadio de la enfermedad (Safdari et al., 2022). A su vez, el desarrollo de modelos interpretables es relevante en el ámbito clínico ya que facilita la comprensión de los factores que influyen en las predicciones y favorece su potencial aplicación en la práctica médica real (Ali et al., 2023). También, es importante destacar que un modelo que el clínico no puede entender difícilmente va a ser adoptado, por más preciso que sea.

De esta manera, el uso de técnicas de machine learning aplicada a datos biomédicos puede representar una herramienta útil y complementaria para apoyar el diagnóstico y estratificación de pacientes con enfermedad hepática. Algunos estudios recientes fueron

más allá y mostraron que estos modelos pueden ayudar incluso a identificar pacientes con hepatitis C no diagnosticada mediante el análisis de registros clínicos, lo que podría contribuir a una mejora en las estrategias de cribado y seguimiento de la enfermedad (Rigg et al., 2023). Además, investigaciones más recientes han explorado el desarrollo de modelos híbridos que combinan diferentes algoritmos con el objetivo de mejorar la precisión en la clasificación de estadios de la enfermedad (Lilhore et al., 2023).

A pesar de los avances en el uso de técnicas de inteligencia artificial aplicadas a la salud, aún existen limitaciones relacionadas con la disponibilidad y accesibilidad de datos, el desbalance entre clases y la interpretación de los modelos en la vida real. Muchos estudios se centraron en modelos complejos o en grandes bases de datos, lo que dificulta su aplicabilidad en entornos clínicos más pequeños y cotidianos, donde predominan las analíticas clásicas y los tamaños muestrales más reducidos. Además, sigue siendo necesario evaluar su utilidad en la clasificación de distintos estadios de enfermedad hepática a partir de variables clínicas accesibles, que es exactamente lo que este trabajo intenta abordar.

El presente trabajo tiene como objetivo aplicar modelos de machine learning para clasificar los diferentes estadios de enfermedad hepática asociados a hepatitis C a partir de parámetros clínicos y bioquímicos de uso habitual en la práctica clínica. Para ello, se utilizó un conjunto de datos con variables demográficas y analíticas de rutina con el fin de evaluar el rendimiento de diferentes modelos predictivos, analizar la relevancia de los marcadores hepáticos en la clasificación de los distintos estadios de la enfermedad, y valorar el potencial de estos enfoques como herramientas complementarias, especialmente desde una perspectiva integradora que contemple tanto aspectos clínicos como metabólicos y nutricionales del paciente.

6. OBJETIVOS

Objetivo general

Desarrollar y evaluar modelos de machine learning supervisado para la clasificación de los distintos estadios de enfermedad hepática asociada a hepatitis C a partir de parámetros clínicos y bioquímicos de uso habitual en la práctica clínica.

Objetivos específicos

1. Describir las características demográficas y bioquímicas de la población estudiada e identificar diferencias en los biomarcadores hepáticos entre los distintos estadios de la enfermedad.
2. Analizar las correlaciones entre las variables clínicas incluidas en el dataset y evaluar su asociación con las categorías diagnósticas mediante contrastes de hipótesis no paramétricos.
3. Comparar el rendimiento diagnóstico de diferentes modelos de clasificación supervisada en la detección de los estadios de enfermedad hepática, con especial atención a la sensibilidad en las clases minoritarias.
4. Identificar las variables bioquímicas con mayor contribución predictiva en la clasificación de los estadios de la enfermedad hepática e interpretar su relevancia desde una perspectiva clínica y metabólica.
5. Evaluar el potencial de los modelos desarrollados como herramienta complementaria de apoyo al diagnóstico clínico en el contexto de la enfermedad hepática crónica asociada a hepatitis C.

7. METODOLOGÍA

7.1 Fuente de datos

Se utilizó un dataset proporcionado por el máster, que incluye información demográfica y parámetros clínicos relacionados con la función hepática.

El dataset original contenía 615 individuos distribuidos en diferentes categorías diagnósticas, incluyendo individuos sanos (0=Blood Donor), pacientes con hepatitis, fibrosis, cirrosis y una categoría denominada “suspect blood donor”. Esta última fue excluida del análisis por no corresponder a ningún estadio diagnóstico definido, resultando en un total de 608 individuos para el análisis. Todo el procesamiento y modelado se realizó en Python, utilizando las librerías pandas, numpy, matplotlib, seaborn y scikit-learn, en el entorno Google Colaboratory.

El hecho de utilizar un dataset facilitado directamente por el programa del máster me permitió centrar todo el esfuerzo del trabajo en las fases de preprocesamiento, análisis exploratorio de datos y desarrollo de modelos de machine learning, que constituyen el núcleo competencial del máster de Bioestadística y bioinformática. Esta aproximación es habitual en los trabajos de máster, ya que favorece el aprendizaje profundo de las técnicas

de análisis y modelado predictivo en un entorno controlado y reproducible, sin la necesidad de dedicar tiempo a la recolección primaria de datos.

El dataset incluye registros de individuos con diferentes diagnósticos, desde donantes de sangre sanos hasta pacientes con hepatitis, fibrosis y cirrosis, lo que lo convierte en un recurso idóneo para el desarrollo de modelos de clasificación multiclase de enfermedad hepática. Su disponibilidad y su composición de variables clínicas de rutina que no requieren pruebas invasivas ni tecnología especializada lo hacen especialmente representativo de los datos que se generan habitualmente en la práctica clínica real. En mi opinión, trabajar con un dataset de estas características tiene un valor añadido importante: los resultados obtenidos son directamente extrapolables, al menos en términos de tipo de variables, a lo que cualquier clínico podría encontrar en su práctica diaria, lo que refuerza la potencial aplicabilidad de los modelos desarrollados.

7.2 Variables incluidas en el análisis

Las variables que se analizaron fueron edad, sexo y biomarcadores hepáticos de uso habitual en la práctica clínica: alanina aminotransferasa (ALT), aspartato aminotransferasa (AST), fosfatasa alcalina (ALP), gamma-glutamyl transferasa (GGT), bilirrubina (BIL), albúmina (ALB), colesterol (CHOL), creatinina (CREA), proteínas totales (PROT) y colinesterasa (CHE). Además, se eliminó la columna "Unnamed: 0", que correspondía a un índice arrastrado por error desde el archivo CSV original y no aportaba información clínica relevante.

7.3 Preprocesamiento de datos

Valores faltantes

Al revisar la calidad de los datos, se identificaron valores faltantes en cinco variables: ALP (n=18), CHOL (n=10), ALB (n=1), ALT (n=1) y PROT (n=1). En todos los casos, el porcentaje de datos faltantes fue inferior al 3% del total de registros, por lo que se optó por imputar con la mediana de cada variable. Esta decisión es la más adecuada cuando las distribuciones son asimétricas (como suele ocurrir con los biomarcadores hepáticos) ya que la mediana es menos sensible a valores extremos que la media, y evita el sesgo que introduciría la eliminación directa de registros.

Codificación de variables categóricas

Las variables categóricas fueron transformadas a formato numérico para poder usarlas en los modelos. La variable sexo fue codificada de forma binaria ($m=0$ y $f=1$) y la variable diagnostica fue recodificada extrayendo el dígito numérico de cada categoría: 0 = sano, 1=hepatitis, 2=fibrosis, 3=cirrosis.

Estandarización

Las variables numéricas fueron estandarizadas mediante StandardScaler de scikit-learn, que transforma cada variable para que tenga media 0 y desviación estándar 1. Esta transformación se aplicó solamente a los modelos de regresión logística, que son sensibles a las diferencias de escala entre variables. El escalado se ajustó sobre el conjunto de entrenamiento y luego se aplicó al conjunto de prueba, evitando así cualquier filtración de información entre ambos conjuntos.

7.4 Análisis exploratorio de datos

Se realizó un análisis exploratorio previo al modelado, con el objetivo de comprender la distribución de las variables y su posible relación con los diferentes estadios de la enfermedad. Para ello, se emplearon representaciones gráficas como diagrama de barras para visualizar la distribución de las categorías diagnósticas, un mapa de calor de correlaciones para identificar relaciones entre las variables y boxplots de los principales biomarcadores (ALT, AST, ALB, GGT y BIL) por categoría diagnóstica. Este análisis permitió identificar un importante desbalance entre clases y los patrones de variación de los biomarcadores entre grupos, orientando las decisiones metodológicas posteriores.

7.5 Desarrollo de modelos predictivos

División del dataset

El dataset se dividió en conjuntos de entrenamiento (80%, $n = 486$) y prueba (20%, $n = 122$), utilizando la función `train_test_split` de scikit-learn con estratificación por clase (`stratify=y`) para preservar la proporción de cada categoría diagnóstica en ambos subconjuntos. Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados.

Justificación de las decisiones metodológicas

Antes de pasar a los resultados, vale la pena detenerse un momento en algunas de las decisiones metodológicas tomadas durante el diseño del análisis, ya que no son arbitrarias y condicionaron directamente lo que se obtuvo.

La proporción de división 80/20 entre entrenamiento y prueba es una de las más utilizadas en machine learning aplicado a datos clínicos, y se consideró la más adecuada para este dataset. Con un tamaño muestral moderado y clases muy desbalanceadas, usar una proporción mayor de datos de prueba habría reducido excesivamente el conjunto de entrenamiento, comprometiendo la estabilidad de los modelos especialmente en las clases minoritarias (que ya de por sí es de muy pocos casos). La estratificación por clase (`stratify=y`) se aplicó precisamente por esto: para garantizar que la distribución de categorías diagnósticas fuera proporcional en ambos subconjuntos y evitar que alguna clase quedara subrepresentada o, en el peor caso, completamente ausente del conjunto de prueba.

La fijación de una semilla aleatoria (`random_state=42`) en todos los procesos estocásticos (la división del dataset y el entrenamiento del Random Forest) garantiza que el análisis sea completamente reproducible. Es decir, permite que cualquier investigador que ejecute el mismo código con los mismos datos obtenga exactamente los mismos resultados. En investigación biomédica esto no es un detalle menor, sino una condición básica de rigor científico.

En cuanto al escalado, se eligió `StandardScaler` porque transforma cada variable para que tenga media 0 y desviación estándar 1. Esto es especialmente relevante en regresión logística, donde el algoritmo es sensible a las diferencias de magnitud entre variables. Un ejemplo concreto de por qué importa: GGT puede alcanzar valores de hasta 650 U/L en este dataset, mientras que CHOL raramente supera los 10 mmol/L. Sin estandarización, la magnitud bruta de GGT dominaría el modelo de forma artificial, independientemente de su relevancia clínica real. Además, el escalado se ajustó exclusivamente sobre el conjunto de entrenamiento y se aplicó después al conjunto de prueba, este es un paso que puede parecer técnico pero que es fundamental para evitar data leakage, es decir, que información del conjunto de prueba se filtre al entrenamiento e infle artificialmente el rendimiento del modelo.

Por último, la elección de `class_weight='balanced'` frente a técnicas de sobremuestreo como SMOTE fue una decisión meditada. La ponderación de clases tiene dos ventajas concretas sobre SMOTE en este contexto: no modifica el dataset original ni introduce muestras sintéticas, preservando así la distribución real de los biomarcadores en los grupos patológicos; y es más sencilla de implementar e interpretar, lo que favorece la reproducibilidad del análisis en entornos con recursos computacionales limitados. En mi opinión, en datasets clínicos pequeños donde cada caso real es valioso, evitar la generación de datos artificiales es una decisión metodológicamente más conservadora y honesta.

7.6 Modelos evaluados

Se desarrollaron tres modelos de aprendizaje supervisado para clasificar los estadios de enfermedad hepática:

El primero fue una regresión logística estándar, que funcionó como punto de partida para comparar los resultados posteriores. Para entrenarla se utilizó la función `LogisticRegression` de la librería `scikit-learn`, configurando el parámetro `max_iter` en 500 para permitir que el modelo tuviera suficientes iteraciones. Este modelo se estrenó con los datos previamente estandarizados.

El segundo modelo fue `Random Forest`, que constituye múltiples árboles de decisión y combina sus predicciones para obtener un resultado más robusto. Se configuró con 200 árboles (`n_estimators=200`) y una semilla aleatoria fija (`Random_state=42`) para garantizar que sean resultados reproducibles. A diferencia del modelo anterior (regresión logística), este no requiere que las variables estén estandarizadas, por lo que se entrenó directamente con los datos originales.

El tercer modelo fue una regresión logística ponderada, idéntica a la primera, pero con una modificación clave: el parámetro `class_weight='balanced'`, que ajusta automáticamente el peso de cada clase durante el entrenamiento en función de su frecuencia. En la práctica, esto significa que el modelo penaliza más los errores cometidos en los grupos con menos casos (hepatitis, fibrosis y cirrosis) compensando así el desbalance entre categorías que se había identificado en el análisis exploratorio. Esta fue, en mi opinión, la decisión metodológica más importante del trabajo, ya que sin este ajuste el modelo simplemente tendía a clasificar casi todo como "sano".

7.7 Métricas de evaluación

Las métricas utilizadas para evaluar el rendimiento de los modelos fueron las habituales en problemas de clasificación clínica, incluyendo precisión global (accuracy), sensibilidad (recall), precisión por clase (precisión), valor F1 y matriz de confusión. Dado el desbalance entre clases, se prestó atención a la sensibilidad de los modelos en las categorías patológicas minoritarias, ya que en el contexto clínico la capacidad de detectar correctamente los casos de enfermedad tiene mayor relevancia que la precisión global.

7.8 Análisis de variables relevantes y contrastes de hipótesis

Se analizaron los coeficientes del modelo de regresión logística ponderada para identificar las variables con mayor contribución en la clasificación de los estadios de enfermedad hepática. Adicionalmente, se realizaron contrastes de hipótesis mediante el test no paramétrico de Kruskal-Wallis para evaluar la existencia de diferencias estadísticamente significativas en los biomarcadores entre los distintos grupos diagnósticos. Se eligió este test por ser adecuado para comparaciones entre más de dos grupos independientes sin asumir normalidad en la distribución de las variables, condición que no puede garantizarse en biomarcadores clínicos con distribuciones generalmente asimétricas.

8. RESULTADOS

8.1 Descripción del dataset

El dataset analizado incluyó inicialmente 615 individuos. Luego de excluir 7 casos clasificados como "suspect blood donor" (una categoría ambigua que no correspondía a ningún estadio diagnóstico definido) se trabajó con un total de 608 individuos. La distribución por categorías quedó de la siguiente manera: 533 individuos sanos (0=Blood Donor), 30 con cirrosis, 24 con hepatitis y 21 con fibrosis (Tabla 1). Este desbalance entre clases fue uno de los aspectos más determinantes del análisis, y condicionó directamente las decisiones metodológicas tomadas posteriormente.

Tabla 1. Características demográficas y distribución diagnóstica de la muestra tras el preprocesamiento del dataset.

Variable	Categoría	n	%
Categoría diagnóstica	Sano (Blood Donor)	533	87,7%
	Cirrosis	30	4,9%
	Hepatitis	24	3,9%
	Fibrosis	21	3,5%
	Total	608	100%
Sexo	Hombre	377	62,0%
	Mujer	238	38,0%
	Total	615*	100%
Edad	Mínima	19 años	-
	Máxima	77 años	-
	Media	47,4 años	-

En cuanto a las variables, el dataset contenía información demográfica (edad y sexo) y once biomarcadores bioquímicos: ALB, ALP, ALT, AST, BIL, CHE, CHOL, CREA, GGT y PROT. Al revisar los valores faltantes, se identificaron ausencias en ALP (n=18), CHOL (n=10), ALB (n=1), ALT (n=1) y PROT (n=1), todas por debajo del 3% del total de registros (Tabla 2). Dado el bajo porcentaje de datos faltantes, se optó por imputar con la mediana de cada variable, una decisión que evita sesgos derivados de la eliminación de registros y es especialmente adecuada para variables con distribuciones asimétricas, como suelen ser los biomarcadores hepáticos.

Tabla 2. Descripción de las variables incluidas en el análisis: tipo, unidad y frecuencia de valores faltantes antes de la imputación.

Variable	Descripción	Tipo	Unidad	Valores faltantes (n)	% faltantes
Age	Edad	Numérica	Años	0	0%
Sex	Sexo	Categórica	m/f → 0/1	0	0%
ALB	Albúmina	Numérica	g/L	1	0,16%
ALP	Fosfatasa alcalina	Numérica	U/L	18	2,96%
ALT	Alanina aminotransferasa	Numérica	U/L	1	0,16%
AST	Aspartato aminotransferasa	Numérica	U/L	0	0%
BIL	Bilirrubina	Numérica	μmol/L	0	0%
CHE	Colinesterasa	Numérica	kU/L	0	0%
CHOL	Colesterol	Numérica	mmol/L	10	1,64%
CREA	Creatinina	Numérica	μmol/L	0	0%
GGT	Gamma-glutamil transferasa	Numérica	U/L	0	0%
PROT	Proteínas totales	Numérica	g/L	1	0,16%

8.2 Análisis exploratorio de datos

Distribución de clases

El análisis exploratorio confirmó el marcado desbalance entre las categorías diagnósticas. Como puede observarse en [la Figura 1](#), la clase de individuos sanos (categoría 0) representa el 87,7% del total de la muestra, mientras que los grupos patológicos (hepatitis, fibrosis y cirrosis) concentran apenas el 12,3% restante. Esta distribución es representativa de lo que ocurre en la práctica clínica real, donde los pacientes con enfermedad establecida son minoría respecto a la población general, pero tiene implicaciones importantes para el entrenamiento de modelos predictivos.




Figura 1. Distribución de las categorías diagnósticas en el dataset tras la exclusión de casos "suspect blood donor" (n=608).

Correlaciones entre variables

Con el objetivo de evaluar las medidas de correlación entre las variables clínicas incluidas en el análisis, se calculó la matriz de correlaciones de Pearson entre todas las variables del dataset (Figura 2). Los patrones de asociación observados resultaron coherentes con la fisiopatología del daño hepático. Las correlaciones más relevantes fueron las siguientes: AST presentó una correlación positiva moderada con la categoría diagnóstica ($r = 0,65$), siendo el biomarcador con mayor asociación directa con la progresión de la enfermedad. BIL mostró una correlación positiva con AST ($r = 0,32$) y negativa con CHE ($r = -0,34$). ALB presentó correlaciones negativas con la categoría diagnóstica ($r = -0,31$) y con BIL ($r = -0,25$). GGT mostró correlación positiva con la categoría diagnóstica ($r = 0,48$) y con AST ($r = 0,50$). CHE y CHOL presentaron correlaciones positivas entre sí ($r = 0,42$).




Figura 2. Mapa de calor de correlaciones entre las variables clínicas y bioquímicas incluidas en el análisis.

Distribución de biomarcadores por categoría diagnóstica

Los boxplots de los principales biomarcadores por categoría diagnóstica (Figuras 3 a 7) evidenciaron diferencias visuales entre los grupos, especialmente para ALT, AST y GGT.




Figura 3. Distribución de ALT según categoría diagnóstica (0=sano, 1=hepatitis, 2=fibrosis, 3=cirrosis).




Figura 4. Distribución de AST según categoría diagnóstica.




Figura 5. Distribución de ALB según categoría diagnóstica.




Figura 6. Distribución de GGT según categoría diagnóstica.




Figura 7. Distribución de BIL según categoría diagnóstica.

En el caso de ALT (Figura 3), se observó una mayor dispersión y valores más elevados en la categoría 2 (fibrosis), con presencia de valores atípicos importantes. La categoría 1 (hepatitis) también mostró valores superiores a los del grupo sano, aunque con mayor variabilidad. AST (Figura 4) presentó un patrón similar, con valores más altos en los grupos patológicos y mayor variabilidad en cirrosis. ALB (Figura 5) mostró una tendencia inversa, con valores más bajos en los estadios más avanzados. GGT (Figura 6) evidenció valores notablemente más altos en grupos patológicos, especialmente en cirrosis. BIL (Figura 7) mostró mayor dispersión en los estadios avanzados, con valores atípicos en cirrosis y fibrosis.

8.3 Modelos de machine learning

El dataset fue dividido en conjunto de entrenamiento (80%, n=486) y conjunto de prueba (20%, n=122), manteniendo la proporción de clases mediante estratificación. Las variables numéricas fueron estandarizadas mediante StandardScaler antes del entrenamiento de los modelos que lo requerían.

Regresión logística

El modelo de regresión logística estándar alcanzó una precisión global (accuracy) del 95%. Sin embargo, al analizar el rendimiento se evidenció que la sensibilidad para detectar hepatitis fue de apenas 0,20, con un F1-score de 0,33 (Tabla 3). La matriz de confusión (Figura 8) lo confirma: de los 5 casos de hepatitis en el conjunto de prueba, solo 1 fue correctamente clasificado, mientras que 3 fueron asignados como sanos y 1 como cirrosis. Fibrosis y cirrosis tuvieron un rendimiento algo mejor, con recall de 0,75 y 0,83 respectivamente.

Tabla 3. Resultados del modelo de regresión logística: precisión, sensibilidad, F1-score y soporte por clase.

Clase	Precisión	Recall	F1-score	Soporte
0 (Sano)	0,96	1,00	0,98	107
1 (Hepatitis)	1,00	0,20	0,33	5
2 (Fibrosis)	1,00	0,75	0,86	4
3 (Cirrosis)	0,83	0,83	0,83	6
Accuracy global			0,95	122
Macro avg	0,95	0,70	0,75	122
Weighted avg	0,95	0,95	0,94	122




Figura 8. Matriz de confusión del modelo de regresión logística estándar.

Random Forest

El modelo Random Forest obtuvo una precisión global del 93%, sin mostrar mejoras sustanciales respecto a la regresión logística estándar en ninguna de las clases minoritarias (Tabla 4). La sensibilidad para hepatitis se mantuvo en 0,20 y la de fibrosis incluso empeoró, bajando a 0,25. La matriz de confusión (Figura 9) muestra que de los 5 casos de hepatitis, solo 1 fue detectado correctamente, mientras que 2 fueron clasificados como sanos y los otros 2 repartidos entre fibrosis y cirrosis. De los 4 casos de fibrosis, solo 1 fue correctamente identificado. Cirrosis fue el grupo mejor clasificado, con un recall de 0,83 igual al modelo anterior.

Tabla 4. Resultados del modelo Random Forest: precisión, sensibilidad, F1-score y soporte por clase.

Clase	Precisión	Recall	F1-score	Soporte
0 (Sano)	0,96	1,00	0,98	107
1 (Hepatitis)	0,50	0,20	0,29	5
2 (Fibrosis)	0,50	0,25	0,33	4
3 (Cirrosis)	0,83	0,83	0,83	6
Accuracy global			0,93	122
Macro avg	0,70	0,57	0,61	122
Weighted avg	0,92	0,93	0,92	122




Figura 9. Matriz de confusión del modelo Random Forest.

Regresión logística ponderada

La regresión logística con ajuste de pesos de clase (`class_weight='balanced'`) fue el modelo que ofreció un rendimiento más equilibrado entre categorías (Tabla 5). La accuracy global se mantuvo en 0,94, prácticamente igual a los modelos anteriores. La sensibilidad para hepatitis pasó de 0,20 a 0,80, para fibrosis de 0,25 a 0,75, y para cirrosis se mantuvo en 0,83. La matriz de confusión (Figura 10) refleja claramente este cambio: de los 5 casos de hepatitis, 4 fueron correctamente clasificados; de los 4 casos de fibrosis, 3 fueron identificados correctamente; y de los 6 casos de cirrosis, 5 fueron bien clasificados. El único costo visible fue una leve reducción en la precisión de la clase sana, donde 4 individuos sanos fueron incorrectamente clasificados como hepatitis y 1 como cirrosis.

Tabla 5. Resultados del modelo de regresión logística ponderada (`class_weight='balanced'`): precisión, sensibilidad, F1-score y soporte por clase.

Clase	Precisión	Recall	F1-score	Soporte
0 (Sano)	1	0,96	0,98	107
1 (Hepatitis)	0.50	0,80	0,62	5
2 (Fibrosis)	0,75	0,75	0,75	4
3 (Cirrosis)	0,71	0,83	0,77	6
Accuracy global			0,94	122
Macro avg	0,74	0,84	0,78	122
Weighted avg	0,96	0,94	0,95	122




Figura 10. Matriz de confusión del modelo de regresión logística ponderada (*class_weight='balanced'*).

Comparación de modelos

La Tabla 6 resume el rendimiento global de los tres modelos evaluados. La regresión logística ponderada fue la que alcanzó el mejor macro avg F1 (0,78), superando tanto a la regresión logística estándar (0,75) como al Random Forest (0,61), lo que corresponde con una mayor capacidad para clasificar de forma equilibrada todos los estadios de la enfermedad.

Tabla 6. Comparación del rendimiento global de los tres modelos evaluados.

Modelo	Accuracy	Macro avg F1	Macro avg Recall
Regresión logística estándar	0,95	0,75	0,70
Random Forest	0,93	0,61	0,57
Regresión logística ponderada	0,94	0,78	0,84

8.4 Variables relevantes

El análisis de los coeficientes del modelo de regresión logística ponderada permitió identificar las variables con mayor contribución en la clasificación. Los coeficientes positivos de mayor magnitud correspondieron a ALP (1,386), colesterol (0,489),

albúmina (0,395) y ALT (0,229). Por otro lado, AST (-2,428), GGT (-1,036) y bilirrubina (-0,741) presentaron los coeficientes negativos de mayor magnitud (Tabla 7).

Tabla 7. *Coeficientes del modelo de regresión logística ponderada para las variables con mayor contribución en la clasificación.*

Variable	Coeficiente
ALP	1.386012
CHOL	0.489251
ALB	0.394725
ALT	0.229047
Age	0.084641
CHE	-0.045440
CREA	-0.271946
Sex	-0.332046
PROT	-0.476933
BIL	-0.741416
GGT	-1.035999
AST	-2.427981

8.5 Contrastes de hipótesis

Se realizaron contrastes de hipótesis mediante el test no paramétrico de Kruskal-Wallis para evaluar si existían diferencias estadísticamente significativas en los biomarcadores entre los distintos grupos diagnósticos. Se eligió este test por ser adecuado para comparaciones entre más de dos grupos independientes cuando no se puede asumir normalidad en la distribución de las variables, lo que es frecuente en biomarcadores clínicos.

Dado que el análisis exploratorio identificó a ALT, AST y ALB como los biomarcadores con mayor variabilidad entre grupos y mayor correlación con la categoría diagnóstica, el contraste de Kruskal-Wallis se aplicó específicamente sobre estas tres variables. Los

resultados mostraron diferencias estadísticamente significativas en los tres casos (Tabla 8):

Tabla 8. Resultados del test de Kruskal-Wallis para las variables con diferencias estadísticamente significativas entre grupos diagnósticos

Variable	Descripción	Estadístico H	p-valor	Interpretación
ALT	Alanina aminotransferasa	21,860	0,00007	Diferencias significativas
AST	Aspartato aminotransferasa	158,142	< 0,001	Diferencias significativas
ALB	Albúmina	58,076	< 0,001	Diferencias significativas

Estas tres variables mostraron diferencias significativas entre los estadios de enfermedad hepática, lo que es consistente con su reconocido papel como marcadores de daño y función hepática en la práctica clínica.

8.6 Estadísticas descriptivas por categoría diagnóstica

La Tabla 9 resume las estadísticas descriptivas de los principales biomarcadores por categoría diagnóstica. Se observaron diferencias en los valores medios entre grupos, especialmente en AST, GGT, BIL y CHE. AST mostró valores medios progresivamente más elevados desde el grupo sano (26,55 U/L) hasta cirrosis (107,46 U/L). GGT presentó un patrón similar, con valores medios de 29,04 U/L en sanos frente a 129,44 U/L en cirrosis. BIL mostró el aumento más marcado en cirrosis (59,13 μ mol/L) respecto al resto de grupos. CHE presentó los valores medios más bajos en el grupo de cirrosis (3,82 kU/L). ALB también mostró una reducción notable en cirrosis (32,80 g/L) respecto al grupo sano (42,24 g/L).

Tabla 9. Estadísticas descriptivas de los biomarcadores por categoría diagnóstica (media $\pm$ desviación estándar; mínimo – máximo).

Variable	Estadístico	Sano (n=533)	Hepatitis (n=24)	Fibrosis (n=21)	Cirrosis (n=30)
ALT	Media $\pm$ DE	26,63 $\pm$ 14,50	26,74 $\pm$ 22,11	59,60 $\pm$ 66,70	22,97 $\pm$ 36,36
	Mín – Máx	2,50 – 118,10	3,80 – 87,00	2,40 – 258,00	0,90 – 159,00
AST	Media $\pm$ DE	26,55 $\pm$ 10,62	75,73 $\pm$ 68,78	81,17 $\pm$ 42,26	107,46 $\pm$ 74,64
	Mín – Máx	12,00 – 188,70	16,70 – 324,00	34,00 – 187,90	19,20 – 319,80
ALB	Media $\pm$ DE	42,24 $\pm$ 5,03	43,83 $\pm$ 3,51	41,76 $\pm$ 3,74	32,80 $\pm$ 5,97
	Mín – Máx	26,20 – 82,20	37,00 – 50,00	36,00 – 49,00	20,00 – 44,00
ALP	Media $\pm$ DE	68,37 $\pm$ 18,23	45,10 $\pm$ 23,37	49,91 $\pm$ 15,55	87,78 $\pm$ 72,14
	Mín – Máx	27,00 – 145,00	19,10 – 114,00	22,90 – 66,00	11,30 – 416,60
GGT	Media $\pm$ DE	29,04 $\pm$ 24,74	92,58 $\pm$ 116,67	79,55 $\pm$ 47,76	129,44 $\pm$ 138,04
	Mín – Máx	4,50 – 239,00	11,50 – 491,00	11,90 – 203,00	17,60 – 650,90
BIL	Media $\pm$ DE	8,53 $\pm$ 6,09	15,62 $\pm$ 13,47	13,43 $\pm$ 5,33	59,13 $\pm$ 69,37
	Mín – Máx	1,80 – 59,10	5,00 – 67,00	6,00 – 30,00	7,00 – 254,00
CHOL	Media $\pm$ DE	5,49 $\pm$ 1,05	5,10 $\pm$ 1,45	4,63 $\pm$ 0,73	4,09 $\pm$ 1,01
	Mín – Máx	2,79 – 9,43	3,09 – 9,67	3,10 – 6,19	1,43 – 6,30
CHE	Media $\pm$ DE	8,40 $\pm$ 1,88	9,28 $\pm$ 2,51	8,33 $\pm$ 1,67	3,82 $\pm$ 2,24
	Mín – Máx	3,90 – 15,43	5,75 – 16,41	3,99 – 11,49	1,42 – 9,07
CREA	Media $\pm$ DE	78,98 $\pm$ 14,51	73,96 $\pm$ 19,77	73,49 $\pm$ 12,92	138,22 $\pm$ 209,56
	Mín – Máx	8,00 – 127,00	45,40 – 147,30	55,20 – 112,00	49,60 – 1079,10
PROT	Media $\pm$ DE	72,11 $\pm$ 4,55	74,70 $\pm$ 6,08	76,10 $\pm$ 5,05	70,12 $\pm$ 7,80
	Mín – Máx	51,00 – 86,50	63,00 – 90,00	66,50 – 84,00	54,20 – 82,70

Nota: DE = desviación estándar. ALT, AST, ALP, GGT en U/L; ALB, PROT en g/L; BIL, CREA en μ mol/L; CHOL en mmol/L; CHE en kU/L.

9. DISCUSIÓN

En este trabajo se desarrollaron modelos de machine learning para clasificar distintos estadios de enfermedad hepática asociada a hepatitis C a partir de parámetros clínicos y bioquímicos analizados en los exámenes de rutina. Los resultados muestran que la regresión logística ponderada fue la que mejor equilibró la detección de pacientes con enfermedad activa sin sacrificar demasiado la precisión global, lo cual resulta consistente con lo que han reportado estudios previos sobre la utilidad del machine learning en este tipo de clasificaciones (Safdari et al., 2022). Personalmente, creo que este resultado

refuerza la idea de que no siempre el modelo más complejo es el más útil, especialmente cuando los datos son limitados.

Rendimiento de los modelos

El modelo de regresión logística estándar alcanzó una precisión global del 95%, pero con una sensibilidad muy baja para detectar hepatitis ($\text{recall} = 0,20$). Esto, que a primera vista podría parecer un buen resultado, en realidad esconde un problema importante: el modelo tiende a clasificar casi todo como "sano" porque esa es la clase dominante, optimizando la precisión global a costa de no detectar los casos que más importan clínicamente. Este fenómeno es frecuente en datasets clínicos con marcado desbalance de clases y representa uno de los principales desafíos metodológicos en este tipo de estudios (Butt et al., 2021).

El Random Forest, por su parte, obtuvo una precisión global del 93% sin mostrar mejoras sustanciales respecto a la regresión logística en las clases minoritarias. Aunque en principio los métodos de ensamble suelen tener mejor rendimiento, en este caso el tamaño reducido de los grupos patológicos probablemente limitó su capacidad para construir árboles suficientemente diversos. Esto coincide con lo señalado por Majzoobi et al. (2022), quienes observaron que Random Forest no necesariamente supera a modelos lineales cuando el volumen de datos disponible es pequeño. Es un recordatorio de que más complejidad no siempre equivale a mejores resultados.

La regresión logística ponderada ($\text{class_weight} = \text{'balanced'}$) fue, en definitiva, el modelo más útil desde una perspectiva clínica. Al asignar mayor peso a los errores en las clases minoritarias durante el entrenamiento, logró mejorar notablemente la sensibilidad para hepatitis (80%), fibrosis (75%) y cirrosis (83%), manteniendo una precisión global del 94%. En contextos clínicos donde el costo de un falso negativo es mucho mayor que el de un falso positivo, esta estrategia tiene mucho sentido, y así lo han señalado también Lilhore et al. (2023) en su propuesta de modelos híbridos para clasificación de hepatitis C.

Mirando los tres modelos en conjunto, llama la atención que la diferencia de rendimiento entre la regresión logística estándar y la ponderada sea tan marcada en sensibilidad pero tan pequeña en accuracy global — apenas un punto porcentual. Esto ilustra de forma muy clara por qué la accuracy no es una métrica suficiente cuando los datos están

desbalanceados: un modelo puede clasificar correctamente el 95% de los casos simplemente aprendiendo a decir siempre "sano", y ese número no dice nada sobre su utilidad clínica real. En este trabajo, la decisión de priorizar el macro avg F1 y el recall por clase como métricas principales fue, en mi opinión, más informativa y clínicamente relevante que quedarse con la accuracy global. Es un aprendizaje que va más allá de este dataset concreto y que aplica a cualquier problema de clasificación médica donde las clases patológicas son minoritarias pero son precisamente las que más importa detectar.

Relevancia clínica de los biomarcadores

Más allá de los números, lo que más me parece valioso de estos resultados es que tienen coherencia biológica. Las variables con mayor peso en el modelo son exactamente las que uno esperaría desde el punto de vista fisiopatológico. La elevación de ALT refleja daño hepatocelular activo; la GGT se asocia con estrés hepático y colestasis; y los cambios en albúmina y proteínas totales hablan del deterioro en la capacidad sintética del hígado, que se acentúa progresivamente a medida que avanza la enfermedad. Estos hallazgos son consistentes con los de Ali et al. (2023), quienes identificaron ALT, AST y albúmina como las variables de mayor poder discriminativo en modelos similares, y con Safdari et al. (2022), que destacaron la relevancia de los biomarcadores clásicos frente a variables más complejas en datos de rutina.

Otro aspecto que merece reflexión es la interpretabilidad de los modelos desarrollados. En el ámbito clínico, un modelo que no puede explicar por qué toma una determinada decisión tiene una utilidad muy limitada, independientemente de su precisión. Un médico no puede ni debe confiar ciegamente en una predicción que no entiende, especialmente cuando esa predicción puede influir en decisiones diagnósticas o terapéuticas con consecuencias reales e importantes para el paciente. En este sentido, la elección de la regresión logística como modelo principal no fue casualidad: es uno de los algoritmos más interpretables disponibles, ya que sus coeficientes permiten cuantificar directamente la contribución de cada variable a la predicción y comunicar esa información de forma comprensible al clínico.

Esta cuestión de la interpretabilidad es precisamente uno de los debates más activos en el campo del machine learning aplicado a medicina. Modelos más complejos como las redes neuronales profundas o los gradient boosting pueden ofrecer mayor precisión en datasets

grandes, pero funcionan esencialmente como cajas negras ya que producen una predicción sin explicar cómo llegaron a ella. Frente a esto, modelos lineales como la regresión logística ofrecen una transparencia que, en contextos clínicos, puede ser más valiosa que unos décimas de punto porcentual adicionales de accuracy. Ali et al. (2023) abordaron precisamente esta limitación en su estudio utilizando valores SHAP para explicar las predicciones de modelos más complejos, lo que representa una solución interesante aunque añade complejidad al pipeline de análisis. En el presente trabajo se optó por una aproximación más directa: usar un modelo que es interpretable por construcción, sin necesidad de herramientas adicionales de explicabilidad.

Desde una perspectiva clínica y práctica, que el modelo indique que AST tiene el coeficiente negativo de mayor magnitud (-2,428) significa que un valor elevado de AST es la señal analítica que más fuertemente orienta al modelo hacia un diagnóstico patológico. Ese tipo de información no solo es útil para la predicción, sino que tiene sentido biológico inmediato y puede integrarse naturalmente en el razonamiento clínico del médico que consulta el modelo. Es, en definitiva, el tipo de herramienta que un clínico podría usar y entender sin necesidad de ser experto en machine learning, lo que aumenta considerablemente su potencial de adopción real.

Desde una perspectiva clínica y nutricional, vale la pena destacar que las alteraciones en marcadores como albúmina o colesterol no solo reflejan daño estructural hepático, sino también cambios metabólicos con implicaciones más amplias. El hígado tiene un rol central en el metabolismo proteico y lipídico, y su deterioro afecta inevitablemente el estado nutricional del paciente. La enfermedad hepática crónica se asocia frecuentemente a inflamación sistémica, alteraciones metabólicas y riesgo de malnutrición, aspectos que influyen tanto en la evolución clínica como en la interpretación de los propios biomarcadores (Plauth et al., 2019). Por eso, incorporar variables nutricionales en futuros modelos no es solo una mejora técnica, sino una necesidad clínica real.

En este sentido, la disminución de albúmina observada en los estadios más avanzados — especialmente en cirrosis, donde la media fue de 32,80 g/L frente a 42,24 g/L en el grupo sano — no solo refleja pérdida de capacidad sintética hepática, sino que también puede indicar un estado de desnutrición proteica que agrava el pronóstico del paciente. Algo similar ocurre con la colinesterasa (CHE), que presentó valores medios notablemente más bajos en cirrosis (3,82 kU/L), dado que esta enzima se sintetiza exclusivamente en el

hígado y su descenso es indicativo tanto de daño hepático avanzado como de deterioro metabólico global. La reducción de colesterol en los grupos patológicos (con una media de 4,09 mmol/L en cirrosis frente a 5,49 mmol/L en sanos) también merece atención desde una perspectiva metabólica y nutricional, ya que el hígado es el principal órgano que produce colesterol endógeno y su descenso puede reflejar una capacidad sintética comprometida con repercusiones en la síntesis de hormonas, vitaminas liposolubles y membranas celulares. En conjunto, estos biomarcadores no son solo indicadores de daño hepático estructural, sino también una ventana al estado metabólico y nutricional del paciente, lo que refuerza aún más la necesidad de una evaluación integral que contemple ambas dimensiones (Plauth et al., 2019; Pratt & Kaplan, 2000).

Comparación con la literatura

Los resultados obtenidos son comparables a los de estudios similares. Butt et al. (2021) reportaron precisiones globales de entre el 90% y el 97% en modelos de clasificación de estadios de hepatitis C, con dificultades análogas en la detección de clases minoritarias. Lilhore et al. (2023), por su parte, lograron mejoras en sensibilidad mediante un modelo híbrido, aunque a expensas de una mayor complejidad. Frente a esas aproximaciones, el enfoque de este trabajo de modelos interpretables basados en parámetros accesibles ofrece una alternativa más aplicable en entornos clínicos reales, donde la interpretabilidad del modelo suele ser tan importante como lo es también su precisión.

Resulta especialmente interesante comparar los resultados de este trabajo con los de Safdari et al. (2022), ya que ambos estudios utilizaron una metodología muy similar en cuanto a la división entrenamiento/prueba (80/20) y el uso de Python con scikit-learn. En su estudio, el modelo de Random Forest alcanzó una precisión global del 97,29% y un F-score del 93,42%, convirtiéndose en el mejor clasificador entre los seis algoritmos evaluados. Sin embargo, y aquí está el punto que me parece más relevante, Safdari et al. (2022) aplicaron SMOTE para equilibrar el dataset antes del entrenamiento, mientras que en el presente trabajo se optó por la ponderación de clases mediante `class_weight='balanced'` directamente en el modelo de regresión logística. Esta diferencia metodológica es clave: SMOTE genera muestras sintéticas nuevas para equilibrar las clases, mientras que la ponderación ajusta el peso de los errores durante el entrenamiento sin modificar el dataset original. Ambas estrategias buscan el mismo objetivo: mejorar la detección de clases minoritarias, pero la ponderación utilizada en este trabajo tiene la

ventaja de no introducir datos artificiales, lo que puede ser preferible en contextos clínicos con muestras pequeñas donde la generación de datos sintéticos podría distorsionar la distribución real de los biomarcadores y así los resultados que se obtienen.

Por su parte, Ali et al. (2023) trabajaron con un dataset diferente que contiene 1801 pacientes del Hospital de la Universidad de Jordania y evaluaron cinco algoritmos combinando selección de variables mediante Sequential Forward Selection (SFS)

y técnicas de augmentación con SMOTE. Sus modelos alcanzaron una precisión media del 83%, inferior a la obtenida en el presente trabajo, lo que puede explicarse por las diferencias en la composición del dataset y el enfoque de clasificación binaria (infectado/no infectado) frente al enfoque multiclase adoptado aquí. Una contribución destacable de Ali et al. (2023) es el uso de valores SHAP para explicar las predicciones del modelo. Aunque el artículo no detalla numéricamente las variables más importantes, el análisis SHAP visual para regresión logística muestra un fuerte impacto de biomarcadores hepáticos como GGT, creatinina y bilirrubina. Este resultado guarda coherencia con los coeficientes obtenidos en el presente trabajo, donde GGT (-1,036), BIL (-0,741) y AST (-2,428) presentaron pesos negativos de gran magnitud. Esta coincidencia entre estudios con datasets distintos refuerza la solidez biológica de estos biomarcadores como predictores del daño hepático.

En esa misma línea, Rigg et al. (2023) demostraron que modelos de machine learning entrenados con registros clínicos de rutina (electronic medical records ambulatorios) pueden identificar de forma eficaz pacientes con hepatitis C no diagnosticada. Este hallazgo refuerza el potencial de estas aproximaciones como herramientas de cribado y priorización para la realización de pruebas dirigidas. Los resultados del presente trabajo apuntan en la misma dirección.

Limitaciones

Es importante ser honesta respecto a las limitaciones del estudio, porque ignorarlas sería hacer un flaco favor a cualquier lector que quiera valorar la aplicabilidad real de estos resultados.

La más evidente es el tamaño muestral reducido de las clases patológicas, hepatitis (n=24) y fibrosis (n=21), lo que limita directamente la estabilidad de los modelos. Con tan pocos

casos en estas categorías, pequeñas variaciones en la partición entrenamiento/prueba podrían producir resultados distintos. En el conjunto de prueba, la clase hepatitis contaba únicamente con 5 casos, lo que significa que un solo caso mal clasificado tiene un impacto del 20% en el recall de esa categoría. Esto hace que los valores de sensibilidad para las clases minoritarias deban interpretarse con cautela, ya que no son estadísticamente robustos con tamaños muestrales tan pequeños.

Otra limitación importante es la ausencia de variables nutricionales y metabólicas en el dataset. Como se ha argumentado a lo largo de este trabajo, el estado nutricional del paciente con enfermedad hepática crónica es relevante tanto para la evolución clínica como para la interpretación de algunos biomarcadores, especialmente albúmina, colesterol y colinesterasa. La incorporación de variables como el índice de masa corporal, la ingesta proteica, marcadores de inflamación sistémica como la proteína C reactiva, o escalas de valoración nutricional validadas como el NRS-2002, podría enriquecer considerablemente la capacidad predictiva de futuros modelos.

Tampoco se realizó una validación externa con un conjunto de datos independiente, lo que sería el paso necesario antes de considerar cualquier aplicación clínica concreta. Un modelo que funciona bien en el dataset UCI no garantiza el mismo rendimiento en datos recogidos en un hospital español con sus propias características poblacionales, protocolos analíticos y distribución de enfermedad. Esta limitación es estructural y no puede resolverse sin acceso a nuevos datos clínicos reales.

Implicaciones clínicas

A pesar de todo lo anterior, creo que los resultados tienen valor práctico real. Que un modelo basado únicamente en analíticas de rutina pueda clasificar estadios de enfermedad hepática con una sensibilidad razonable es realmente un hallazgo relevante. Y lo que me parece especialmente valioso es que no requiere tecnología costosa ni infraestructura especializada, como hemos dicho anteriormente los biomarcadores utilizados están disponibles en cualquier laboratorio clínico de atención primaria o secundaria.

Pensando en un escenario concreto de aplicación, este tipo de modelo podría integrarse como herramienta de apoyo en consultas de medicina interna, hepatología o atención primaria, donde el clínico introduce los resultados analíticos de rutina del paciente y el

modelo devuelve una probabilidad de pertenencia a cada estadio diagnóstico. No reemplazaría al diagnóstico clínico ni a pruebas como la biopsia hepática o la elastografía, pero sí podría orientar la toma de decisiones sobre qué pacientes requieren una evaluación más profunda, especialmente en entornos con recursos limitados o listas de espera prolongadas. Esta función de triaje complementario es precisamente donde los modelos interpretables como la regresión logística tienen mayor potencial, ya que el clínico puede entender qué variables están influyendo en la predicción y discutirlos con el paciente de forma transparente.

En el contexto español, donde la prevalencia de hepatitis C no diagnosticada sigue siendo un desafío sanitario relevante (Hernando et al., 2024), herramientas de este tipo podrían contribuir a mejorar las estrategias de cribado y seguimiento, identificando de forma proactiva a pacientes con patrones analíticos compatibles con enfermedad hepática activa antes de que alcancen estadios avanzados. También podrían ser de suma importancia a la hora de hablar de prevención y no solo de tratamiento de enfermedades.

Hacia adelante, los pasos naturales para desarrollar modelos más generalizables y clínicamente útiles serían integrar variables nutricionales y metabólicas, ampliar el tamaño muestral con datos de múltiples centros, incorporar validación cruzada más robusta y, en una fase posterior, realizar un estudio de validación prospectiva en un entorno clínico real. Sin ese paso final, cualquier modelo, por preciso que sea en el conjunto de prueba, sigue siendo una promesa más que una herramienta.

En definitiva, este trabajo representa un ejercicio de machine learning aplicado a un problema clínico real, con datos reales, limitaciones reales y resultados que -dentro de esas limitaciones- son coherentes, reproducibles y biológicamente plausibles. No pretende ser la solución definitiva al diagnóstico de la enfermedad hepática, sino una demostración de que aproximaciones metodológicas relativamente sencillas, basadas en parámetros accesibles y modelos interpretables, pueden ofrecer valor clínico genuino. El camino hacia modelos más robustos y generalizables pasa necesariamente por más datos, más variables y validación prospectiva, pero ese camino tiene que empezar en algún punto, y este trabajo intenta ser un paso en esa dirección.

Mirando hacia adelante, las líneas de trabajo futuro que se desprenden de este estudio son variadas y, en mi opinión, genuinamente interesantes de explorar.

La más inmediata sería ampliar el tamaño muestral, especialmente en las clases patológicas minoritarias. Con apenas 24 casos de hepatitis y 21 de fibrosis, los modelos actuales operan al límite de lo que es estadísticamente estable. Idealmente un estudio futuro debería contar con al menos 100 casos por categoría diagnóstica para que las métricas de rendimiento sean robustas y generalizables. Esto requeriría datos de múltiples centros clínicos, lo que a su vez abriría la posibilidad de evaluar si los modelos funcionan igual de bien en poblaciones con características demográficas y epidemiológicas distintas, esto es una pregunta que este trabajo, por sus limitaciones, no puede responder.

La incorporación de variables nutricionales y metabólicas sería otro paso natural y clínicamente relevante. Variables como el índice de masa corporal, la ingesta proteica estimada, marcadores de inflamación sistémica como la proteína C reactiva o la interleucina-6, o escalas de valoración nutricional validadas como el NRS-2002 o el MUST, podrían enriquecer considerablemente la capacidad predictiva de los modelos. El hígado tiene un rol central en el metabolismo y la nutrición, y es razonable pensar que el estado nutricional del paciente aporta valiosa información complementaria a la que ofrecen los biomarcadores bioquímicos clásicos. Explorar esta hipótesis de forma sistemática sería, desde mi punto de vista, una de las contribuciones más originales que podría hacer un trabajo futuro en este campo.

Otra línea interesante sería explorar técnicas de validación cruzada más robustas, como la validación cruzada estratificada k-fold, que permitiría aprovechar mejor los datos disponibles y obtener estimaciones más fiables del rendimiento real del modelo. En datasets pequeños como el utilizado en este trabajo, la partición única 80/20 puede producir estimaciones variables dependiendo de cómo se distribuyen aleatoriamente los casos; la validación cruzada mitiga este problema al evaluar el modelo sobre múltiples particiones del dataset.

Finalmente, el paso más importante y también el más ambicioso sería realizar un estudio de validación prospectiva en un entorno clínico real. Esto implicaría recoger datos de pacientes nuevos en un hospital o centro de atención primaria, aplicar el modelo entrenado y comparar sus predicciones con el diagnóstico clínico definitivo. Sin este paso, cualquier modelo, mas allá de que funcione en el conjunto de prueba, sigue siendo una herramienta experimental. La validación prospectiva es lo que convierte un modelo de

investigación en una herramienta clínica real, y es el estándar que la comunidad científica y regulatoria exige antes de considerar su implementación en la práctica médica.

10. CONCLUSIÓN

Los modelos de machine learning desarrollados en este trabajo permitieron clasificar los distintos estadios de enfermedad hepática asociada a hepatitis C con resultados favorables. De los tres modelos evaluados, la regresión logística ponderada fue, sin duda, el más relevante desde una perspectiva clínica. Al incorporar el ajuste de pesos de clase, logro mejorar notablemente la detección de los estadios patológicos, alcanzando una sensibilidad del 80% para hepatitis, 75% para fibrosis y 83% para cirrosis. Este resultado confirma que abordar el desbalance entre las clases no es un detalle técnico menor, sino una decisión metodológica con impacto clínico directo.

Resulta especialmente valioso el hecho de que los modelos se basan exclusivamente en biomarcadores de uso habitual en los controles analíticos rutinarios, lo que aumenta considerablemente su aplicabilidad en diferentes entornos clínicos reales.

El hígado desempeña un papel central en el metabolismo proteico y lipídico, por lo que las alteraciones observadas en marcadores hepáticos como albumina, colesterol o las transaminasas no solo reflejan daño estructural hepático, sino también cambios metabólicos con implicaciones nutricionales que merecen atención en el manejo integral del paciente.

A pesar del tamaño reducido de las clases patológicas, que ha limitado la estabilidad y generalización de los modelos, este trabajo demuestra que aproximaciones relativamente sencillas y basadas en datos de fácil acceso pueden ofrecer valor clínico real. En futuros estudios sería deseable ampliar el volumen de datos, incorporar variables nutricionales y metabólicas y realizar una validación externa con conjuntos independientes, con el fin de obtener modelos un poco mas robustos y generalizables.

En definitiva, este TFM constituye un ejemplo practico de como el machine learning puede contribuir a la detección temprana de la enfermedad hepática, asi como también a tomar medidas de prevención, utilizando únicamente información clínica de rutina, sentando una base solida para investigaciones mas ambiciosas en este campo.

11. BIBLIOGRAFÍA

- Ali, M., et al. (2023). Explainable machine learning approach for hepatitis C diagnosis using SFS feature selection. *Machines*, 11(3), 391. <https://doi.org/10.3390/machines11030391>
- Butt, A. H., et al. (2021). Diagnosing the stage of hepatitis C using machine learning. *Journal of Healthcare Engineering*, 2021, 1–10. <https://pubmed.ncbi.nlm.nih.gov/35028114/>
- Coalition for Global Hepatitis Elimination. (2024). *10 years of the Strategic Plan for Tackling Hepatitis C in the Spanish National Health System (PEAHC)*. <https://www.globalhep.org/tools-resources/resources/10-years-strategic-plan-tackling-hepatitis-c-spanish-national-health>
- European Association for the Study of the Liver. (2018). EASL recommendations on treatment of hepatitis C. *Journal of Hepatology*, 69(2), 461–511. <https://pubmed.ncbi.nlm.nih.gov/29650333/>
- Ermaya, Y. S. (2023). How to interpret liver function tests in clinical practice. *Archives of Pediatric Gastroenterology, Hepatology and Nutrition*, 2(1), 40–52. <https://apghn.com/index.php/journal/article/download/35/51>
- European Centre for Disease Prevention and Control. (2024). *Hepatitis C. Annual epidemiological report for 2022*. Stockholm: ECDC. <https://www.ecdc.europa.eu/en/publications-data/hepatitis-c-annual-epidemiological-report-2022>
- European Centre for Disease Prevention and Control. (2025). *Hepatitis C. Annual epidemiological report for 2023*. Stockholm: ECDC. <https://www.ecdc.europa.eu/en/publications-data/hepatitis-c-annual-epidemiological-report-2023>
- Žigutyte, L., et al. (2024). Use of artificial intelligence for liver diseases: A survey from the EASL congress 2024. *JHEP Reports*, 6(12), Article 101209. <https://doi.org/10.1016/j.jhepr.2024.101209>

Hernando, V., Simón, L., Villegas, T., Díaz, A., y Red Nacional de Vigilancia Epidemiológica. (2024). *Vigilancia epidemiológica de la hepatitis C en España, 2022*. Centro Nacional de Epidemiología, Instituto de Salud Carlos III. https://cne.isciii.es/documents/d/cne/vigilancia_hepatitisc_2022

Kwo, P. Y., Cohen, S. M., & Lim, J. K. (2017). ACG clinical guideline: Evaluation of abnormal liver chemistries. *The American Journal of Gastroenterology*, 112(1), 18–35. <https://pubmed.ncbi.nlm.nih.gov/27995906/>

Lilhore, U. K., et al. (2023). Hybrid model for precise hepatitis-C classification using improved random forest and SVM method. *Scientific Reports*, 13(1), 12473. <https://doi.org/10.1038/s41598-023-36605-3>

Majzoobi, M., et al. (2022). Prediction of hepatitis disease using ensemble learning methods. *Healthcare*, 10(10), 1976. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9648545/>

Maticic, M., et al. (2024). How far are we? Assessing progress in hepatitis C response towards the WHO 2030 elimination goals by the civil society monitoring in 25 European countries, period 2020 to 2023. *Harm Reduction Journal*, 21(1), 203. <https://pubmed.ncbi.nlm.nih.gov/39563360/>

Ministerio de Sanidad. (2023). *Sanidad constata la mejora en la detección precoz de la hepatitis C y el avance hacia la eliminación de las hepatitis víricas*. Gobierno de España. <https://www.sanidad.gob.es/gabinete/notasPrensa.do?id=6237>

Mohammed, A. A., Al-Hassnawi, A. T., & Ghali, H. H. (2017). Serum cholinesterase as liver function test in cirrhotic patients. *International Research Journal of Medicine and Medical Sciences*, 5(3), 44–49. <https://www.netjournals.org/pdf/IRJMMS/2017/3/17-029.pdf>

Ozer, J., Ratner, M., Shaw, M., Bailey, W., & Schomaker, S. (2008). The current state of serum biomarkers of hepatotoxicity. *Toxicology*, 245(3), 194–205. <https://pubmed.ncbi.nlm.nih.gov/18291570/>

Plauth, M., Bernal, W., Dasarathy, S., Merli, M., Plank, L. D., Schütz, T., & Bischoff, S. C. (2019). ESPEN guideline on clinical nutrition in liver disease. *Clinical Nutrition*, 38(2), 485–521. <https://pubmed.ncbi.nlm.nih.gov/30712783/>

- Pratt, D. S., & Kaplan, M. M. (2000). Evaluation of abnormal liver-enzyme results in asymptomatic patients. *New England Journal of Medicine*, 342(17), 1266–1271. <https://www.nejm.org/doi/10.1056/NEJM200004273421707>
- Rigg, J., et al. (2023). Finding undiagnosed patients with hepatitis C virus: an application of machine learning to US ambulatory electronic medical records. *BMJ Health Care Inform*, 30(1), e100651. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9843171/>
- Safdari, R., Deghatipour, A., Gholamzadeh, M., & Maghooli, K. (2022). Applying data mining techniques to classify patients with suspected hepatitis C virus infection. *Intelligent Medicine*, 2(4), 193–198. <https://doi.org/10.1016/j.imed.2021.12.003>
- Schattenberg, J. M., Chalasani, N., & Alkhouri, N. (2023). Artificial intelligence applications in hepatology. *Clinical Gastroenterology and Hepatology*, 21(8), 2015–2025. <https://doi.org/10.1016/j.cgh.2023.04.007>
- Thapa, B. R., & Walia, A. (2007). Liver function tests and their interpretation. *Indian Journal of Pediatrics*, 74(7), 663–671. <https://pubmed.ncbi.nlm.nih.gov/17699976/>
- World Health Organization. (2017). *Global hepatitis report 2017*. <https://www.who.int/publications/i/item/9789241565455>

12. ANEXO CON EL CÓDIGO UTILIZADO

El código completo del preprocesamiento, análisis exploratorio y los tres modelos de machine learning (regresión logística estándar, random forest y regresión logística ponderada) esta disponible en el siguiente enlace de Google Colab, de acceso público:

<https://colab.research.google.com/drive/1bjXnD5gXRyJcgfPxbCJ0ZeZTFjntP2M3?usp=sharing>

Desde este enlace se puede visualizar el notebook completo y descargarlo.